













Wnioski – eksperyment 1

Pierwszy eksperyment miał na celu weryfikację użyteczności miar wewnętrznych do analizy struktury danych w środowisku pozbawionym prawdziwych etykiet klas. Obserwacja miary Silhouette Score w zależności od parametrów prowadzi do następujących wniosków:

- **Poszukiwanie separacji:** Metryka Silhouette nagradza konfiguracje charakteryzujące się wysoką zwartością klastrów oraz ich silnym oddzieleniem od siebie. Optymalny parametr skutkuje podziałem, w którym granice decyzyjne (np. krawędzie na diagramach Woronoja) przebiegają przez obszary o najniższej gęstości, tworząc wokół klastrów "puste terytoria". Potwierdzają to wyniki dla zbiorów 2_1 oraz 3_1, gdzie na wygenerowanych wykresach najwyższe maksima miary Silhouette idealnie pokrywają się z czystym, odseparowanym podziałem wizualnym.
- **Diagnozowanie struktury centroidowej:** W przypadku metody K-Means, ostry odchył na wykresie Silhouette dowodzi istnienia w przestrzeni wyraźnych, kulistych grup punktów. Widoczne jest to na wykresach z dla zbiorów takich jak 3_2. Z kolei płaski lub łagodnie opadający przebieg miary (jak dla zbioru 3_3) prawidłowo diagnozuje równomierny rozkład danych i całkowity brak odseparowanych wysp.
- **Ograniczenia miary:** Poleganie wyłącznie na Silhouette może być wysoce zwodnicze przy klastrach o złożonych, nieliniowych kształtach, z którymi z natury dobrze radzi sobie DBSCAN. Zjawisko to uwydatniła analiza zbioru 2_2 (półksiężycy). Odległość punktów leżących na przeciwnych krańcach tego samego powoduje zaniżenie wyniku Silhouette, przez co miara ta niesłusznie faworyzuje sztuczne, błędne przecięcie spójnego pierścienia na mniejsze fragmenty.


Wnioski – eksperyment 2

Drugi eksperyment polegał na obiektywnej ocenie wyników poprzez zderzenie ich z prawdziwymi etykietami. Jako główne kryterium wyboru modeli zastosowano miarę Adjusted Rand Score (ARI). Obserwacja miar zewnętrznych pozwala trafnie ocenić separowalność klas:

- **Wysokie wartości ARI (bliskie 1.0):** Stanowią bezpośredni dowód na doskonałą separowalność klas w przestrzeni badanych cech. Oznacza to, że algorytmy bezbłędnie identyfikują granice grup. Ostatecznym sprawdzianem wizualnym był tu zbiór 2_2 – osiągnięcie przez DBSCAN wyniku ARI równego 1.0 udowodniło twardą separowalność struktur, z którą algorytm centroidowy sobie nie poradził.
- **Zjawisko przeuczenia:** Sytuacja ta ma miejsce, gdy miara Homogeneity osiąga wyniki bliskie 1.0 przy jednoczesnym, drastycznym spadku miary Completeness. Dla najmniejszych badanych wartości parametru eps (DBSCAN) lub dużych wartości k (K-Means), algorytmy stają się wtedy zbyt wrażliwe i sztucznie rozbijają naturalne, spójne klasy na wiele bezużytecznych mikro-klastrów.
- **Zjawisko nadmiernej agregacji:** Jest to błąd przeciwny, objawiający się wysokim poziomem Completeness przy niskiej Homogeneity oraz spadającym wyniku ARI. Zostało to świetnie uwidocznione na wykresach miar zewnętrznych dla DBSCAN (m.in. dla zbioru 3_1), gdzie zbyt wysoki parametr eps zmusił algorytm do zlania kilku odrębnych, przylegających do siebie klas w jeden gigantyczny klaster.

Iris

Analiza zbioru Iris stanowi doskonałą ilustrację problemu opisanego we wnioskach z pierwszego eksperymentu. Oceniając jakość algorytmu K-Means za pomocą Silhouette Score, algorytm wskazuje na parametr $k=2$ jako optymalny podział. Sugeruje to, że zbiór składa się z dwóch głównych, odseparowanych od siebie grup punktów. Zderzenie tego wyniku z miarą zewnętrzną ujawnia jednak błąd tego założenia – miara Adjusted Rand Score (ARI) wskazuje, że najwyższe dopasowanie do rzeczywistych etykiet występuje dla parametru $k=3$. Ta rozbieżność jest dowodem na brak separowalności liniowej wszystkich klas. Potwierdza to, że najwyższy wynik Silhouette Score nie zawsze odzwierciedla prawdziwą strukturę danych.



Wine

Zbiór Wine posłużył do weryfikacji skuteczności badanych metod w środowisku wielowymiarowym, gdzie bezpośrednia wizualizacja struktury jest niemożliwa. Dla algorytmu K-Means miara ARI osiąga tu zdecydowane maksimum przy $k=3$ (przy jednoczesnym zbalansowaniu miar Homogeneity i Completeness). Tak wysoki wynik pozwala udowodnić, że pomimo obecności aż 13 wymiarów, obiekty w tym zbiorze są wysoce separowalne, a algorytm skutecznie izoluje poszczególne klasy. Zupełnie odmienne rezultaty przyniósł algorytm DBSCAN, który przy relatywnie małym ϵ tworzył klastry jednoelementowe, a przy jego zwiększaniu wyniki dalej były niesatysfakcjonujące. Zjawisko to pokazuje, że algorytmy gęstościowe, zastosowane bez uprzedniej redukcji wymiarów, tracą swoją skuteczność w złożonych przestrzeniach o dużej liczbie cech.

