













Wnioski – eksperyment 1

Pierwszy eksperyment miał na celu weryfikację użyteczności miar wewnętrznych do analizy struktury danych w środowisku pozbawionym prawdziwych etykiet klas. Obserwacja miary Silhouette Score w zależności od parametrów prowadzi do następujących wniosków:

- **Poszukiwanie separacji:** Metryka Silhouette nagradza konfiguracje charakteryzujące się wysoką zwartością klastrów oraz ich silnym oddzieleniem od siebie. Optymalny parametr skutkuje podziałem, w którym granice decyzyjne (np. krawędzie na diagramach Woronoja) przebiegają przez obszary o najniższej gęstości, tworząc wokół klastrów "puste terytoria". Potwierdzają to wyniki dla zbiorów 2_1 oraz 3_1, gdzie na wygenerowanych wykresach najwyższe maksima miary Silhouette idealnie pokrywają się z czystym, odseparowanym podziałem wizualnym.
- **Diagnozowanie struktury centroidowej:** W przypadku metody K-Means, ostry odchył na wykresie Silhouette dowodzi istnienia w przestrzeni wyraźnych, kulistych grup punktów. Widoczne jest to na wykresach z dla zbiorów takich jak 3_2. Z kolei płaski lub łagodnie opadający przebieg miary (jak dla zbioru 3_3) prawidłowo diagnozuje równomierny rozkład danych i całkowity brak odseparowanych wysp.
- **Ograniczenia miary:** Poleganie wyłącznie na Silhouette może być wysoce zwodnicze przy klastrach o złożonych, nieliniowych kształtach, z którymi z natury dobrze radzi sobie DBSCAN. Zjawisko to uwydatniła analiza zbioru 2_2 (półksiężycy). Odległość punktów leżących na przeciwnych krańcach tego samego powoduje zaniżenie wyniku Silhouette, przez co miara ta niesłusznie faworyzuje sztuczne, błędne przecięcie spójnego pierścienia na mniejsze fragmenty.


Wnioski – eksperyment 2

Drugi eksperyment polegał na obiektywnej ocenie wyników poprzez zderzenie ich z prawdziwymi etykietami. Jako główne kryterium wyboru modeli zastosowano miarę Adjusted Rand Score (ARI). Obserwacja miar zewnętrznych pozwala trafnie ocenić separowalność klas:

- **Wysokie wartości ARI (bliskie 1.0):** Stanowią bezpośredni dowód na doskonałą separowalność klas w przestrzeni badanych cech. Oznacza to, że algorytmy bezbłędnie identyfikują granice grup. Ostatecznym sprawdzianem wizualnym był tu zbiór 2_2 – osiągnięcie przez DBSCAN wyniku ARI równego 1.0 udowodniło twardą separowalność struktur, z którą algorytm centroidowy sobie nie poradził.
- **Zjawisko przeuczenia:** Sytuacja ta ma miejsce, gdy miara Homogeneity osiąga wyniki bliskie 1.0 przy jednoczesnym, drastycznym spadku miary Completeness. Dla najmniejszych badanych wartości parametru eps (DBSCAN) lub dużych wartości k (K-Means), algorytmy stają się wtedy zbyt wrażliwe i sztucznie rozbijają naturalne, spójne klasy na wiele bezużytecznych mikro-klastrów.
- **Zjawisko nadmiernej agregacji:** Jest to błąd przeciwny, objawiający się wysokim poziomem Completeness przy niskiej Homogeneity oraz spadającym wyniku ARI. Zostało to świetnie uwidocznione na wykresach miar zewnętrznych dla DBSCAN (m.in. dla zbioru 3_1), gdzie zbyt wysoki parametr eps zmusił algorytm do zlania kilku odrębnych, przylegających do siebie klas w jeden gigantyczny klaster.


Iris


Analiza zbioru Iris stanowi doskonałą ilustrację problemu opisanego we wnioskach z pierwszego eksperymentu. Oceniając jakość algorytmu K-Means za pomocą Silhouette Score, algorytm wskazuje na parametr $k=2$ jako optymalny podział. Sugeruje to, że zbiór składa się z dwóch głównych, odseparowanych od siebie grup punktów. Zderzenie tego wyniku z miarą zewnętrzną ujawnia jednak błąd tego założenia – miara Adjusted Rand Score (ARI) wskazuje, że najwyższe dopasowanie do rzeczywistych etykiet występuje dla parametru $k=3$. Ta rozbieżność jest dowodem na brak separowalności liniowej wszystkich klas. Potwierdza to, że najwyższy wynik Silhouette Score nie zawsze odzwierciedla prawdziwą strukturę danych.





Wine


Zbiór Wine posłużył do weryfikacji skuteczności badanych metod w środowisku wielowymiarowym, gdzie bezpośrednia wizualizacja struktury jest niemożliwa. Dla algorytmu K-Means miara ARI osiąga tu zdecydowane maksimum przy $k=3$ (przy jednoczesnym zbalansowaniu miar Homogeneity i Completeness). Tak wysoki wynik pozwala udowodnić, że pomimo obecności aż 13 wymiarów, obiekty w tym zbiorze są wysoce separowalne, a algorytm skutecznie izoluje poszczególne klasy. Zupełnie odmienne rezultaty przyniósł algorytm DBSCAN, który przy relatywnie małym ϵ tworzył klastry jednoelementowe, a przy jego zwiększaniu wyniki dalej były niesatysfakcjonujące. Zjawisko to pokazuje, że algorytmy gęstościowe, zastosowane bez uprzedniej redukcji wymiarów, tracą swoją skuteczność w złożonych przestrzeniach o dużej liczbie cech.
























Próba	Ep1_Tr	Ep1_Te	Best_Tr	Best_Te	Best_Ep	Last_Tr	Last_Te
1	0.497908	0.500000	0.690377	0.883333	428	0.686192	0.850000
2	0.502092	0.500000	0.702929	0.800000	834	0.719665	0.783333
3	0.439331	0.466667	0.665272	0.783333	250	0.736402	0.766667
4	0.502092	0.500000	0.723849	0.933333	295	0.707113	0.883333
5	0.694561	0.833333	0.723849	0.933333	149	0.723849	0.916667
6	0.343096	0.283333	0.719665	0.933333	563	0.711297	0.933333
7	0.502092	0.500000	0.702929	0.916667	963	0.702929	0.900000
8	0.502092	0.500000	0.723849	0.933333	861	0.723849	0.916667
9	0.309623	0.233333	0.748954	0.883333	885	0.748954	0.883333
10	0.502092	0.500000	0.744770	0.866667	581	0.753138	0.866667



Próba	Ep1_Tr	Ep1_Te	Best_Tr	Best_Te	Best_Ep	Last_Tr	Last_Te
1	0.627119	0.533333	0.745763	0.666667	854	0.745763	0.666667
2	0.457627	0.433333	0.762712	0.666667	635	0.762712	0.666667
3	0.508475	0.416667	0.745763	0.700000	800	0.745763	0.650000
4	0.508475	0.500000	0.796610	0.716667	245	0.762712	0.650000
5	0.711864	0.616667	0.762712	0.683333	48	0.745763	0.683333
6	0.491525	0.500000	0.745763	0.733333	408	0.762712	0.666667
7	0.491525	0.500000	0.762712	0.650000	83	0.745763	0.633333
8	0.423729	0.500000	0.796610	0.733333	369	0.745763	0.683333
9	0.610169	0.566667	0.762712	0.683333	154	0.762712	0.666667
10	0.525424	0.533333	0.796610	0.716667	164	0.762712	0.666667

Wpływ hiperparametrów

Eksperymenty potwierdziły, że dobór hiperparametrów stanowi narzędzie do bezpośredniego sterowania balansem między niedouczeniem (underfitting) a przeuczeniem (overfitting) modelu.

- **SVM (Support Vector Machine):** Eksperyment udowodnił, że jądro liniowe (*linear*) jest niewystarczające dla struktur nieliniowych (*zbiór 2_3*), a zmiana na jądro *rbf* drastycznie poprawia skuteczność. Z kolei Eksperyment 2 obrazuje rolę parametru *C*. Należy zauważyć, że dla bardzo małych wartości parametru *C* (np. 0.01) model wpada w skrajne niedouczenie – tolerancja dla błędów jest tak duża, że granica decyzyjna całkowicie zanika (klasyfikując całą przestrzeń jako jedną klasę). *C* usztywnia granicę i idealnie dopasowuje ją do danych treningowych, jednak skrajnie duże wartości prowadzą do przeuczenia.
- **MLP (Sieci Neuronowe):** Funkcja aktywacji *relu* wprowadza niezbędną nieliniowość w przeciwieństwie do funkcji *identity*, która redukuje sieć do prostego modelu liniowego. Zwiększanie liczby neuronów w warstwie ukrytej pozwala na tworzenie coraz bardziej skomplikowanych i granic decyzyjnych.
- **K-NN (K-Najbliższych Sąsiadów):** Zbyt niska wartość ($k=1$) sprawia, że granica tworzy wyizolowane wyspy, co jest klasycznym przykładem przeuczenia. Wzrost wartości *k* uśrednia i wygładza granice, poprawiając zdolność uogólniania, lecz zbyt duże *k* zbytnio upraszcza podział, prowadząc do niedouczenia.

Wpływ wielkości zbioru treningowego

Zestawienie Eksperymentu 2 (80% danych treningowych) z Eksperymentem 3 (20% danych treningowych) obnaża podatność modeli na braki w danych.

- **Ogólna obserwacja:** Redukcja danych drastycznie obniża stabilność wszystkich klasyfikatorów. Modele wyuczone na małym zbiorze generują chaotyczne, nieregularne granice, mocno uwarunkowane pojedynczymi (często odstającymi) punktami.
- **K-NN i SVM:** Na małym zbiorze zbiór wektorów nośnych i sąsiadów jest na tyle ubogi, że granica ulega mocnemu przesunięciu, "odcinając" duże obszary przestrzeni należące faktycznie do innej klasy, co rzutuje na wyraźny spadek *accuracy* na zbiorze testowym.
- **MLP:** Mały zbiór sprawia, że sieć neuronowa niezwykle szybko uczy się danych "na pamięć".

Dynamika procesu uczenia i znaczenie inicjalizacji wag

Analiza iteracyjna sieci neuronowej (Eksperyment 4) dostarcza kluczowych informacji o mechanice jej działania:

- **Przebieg epok:** Na początkowym etapie nauki (pierwsza epoka) granica jest niemal przypadkowa. Następnie dopasowuje się ona do rzeczywistego rozkładu danych. Co istotne, kontynuowanie nauki do samego końca (ostatnia epoka) bardzo często powoduje zjawisko przeuczenia – *accuracy* na zbiorze treningowym rośnie (granica zaczyna obrysowywać pojedyncze kropki), ale na testowym zaczyna spadać. Udowadnia to potrzebę stosowania metody wczesnego zatrzymywania nauki.
- **Inicjalizacja wag:** Tabela wielokrotnych uruchomień udowadnia, że ten sam model, na tych samych danych, osiąga różne wyniki w zależności od losowych wag początkowych. Różnice te potrafią sięgać kilku punktów procentowych, co udowadnia, że pojedynczy proces treningu MLP może być niemiernodajny.

Szczegółowe wyniki klasyfikacji na danych rzeczywistych:

Zbiór	Model	Accuracy	Precision (Macro)	Recall (Macro)	F1 Score (Macro)
Iris	K-NN	0.933	0.944	0.933	0.933
Iris	SVM	0.967	0.970	0.967	0.967
Iris	MLP	0.933	0.933	0.933	0.933
Wine	K-NN	0.972	0.970	0.976	0.972
Wine	SVM	0.972	0.978	0.967	0.971
Wine	MLP	0.944	0.951	0.943	0.945

Analiza skuteczności na rzeczywistych zbiorach danych

Weryfikację modeli przeprowadzono na wielowymiarowych zbiorach Iris (4 cechy) oraz Wine (13 cech). Ze względu na wieloklasowość problemu (po 3 klasy), ocenę rozszerzono o miary Precision, Recall oraz F1-score (uśrednianie *macro*).

Ocena skuteczności i wnioski

- **Zbiór Iris:** W przypadku prostszych danych, modele osiągnęły zbliżone wyniki. Najlepiej wypadł SVM (0.967 we wszystkich miarach). Opierając się na wnioskach z Eksperymentów 1 i 3: optymalizacja marginesów i wykorzystanie jądra *rbf* pozwala na wyznaczenie gładkiej granicy, elastycznie rozdzielającej nakładające się na siebie klasy. Z kolei K-NN (0.933) wykazał się typową dla siebie wrażliwością na lokalne zagęszczenia punktów (szum), co obniżyło jego wynik.
- **Zbiór Wine:** Ten zbiór doskonale udowadnia siłę standaryzacji. Zrównanie rzędów wielkości dla 13 cech pozwoliło K-NN osiągnąć wynik na równi z SVM (Accuracy = 0.972). Wyjaśnia to mechanika zbadana w Eksperymentie 2 – K-NN opiera się wyłącznie na odległościach przestrzennych, więc bez standaryzacji cechy o nominalnie dużych wartościach całkowicie zdominowałyby podział. SVM okazał się jednak dokładniejszy w obszarze najwyższej precyzji (0.978). Elastyczność nieliniowego jądra skutecznie zminimalizowała błędne przypisania na krawędziach wielowymiarowych klastrów.
- **Niestabilność MLP:** Sieć neuronowa wypadła najgłębiej na obu zbiorach (0.933 i 0.944). Skomplikowana architektura MLP przy niedużej liczbie próbek uczących gwałtownie prowadzi do przeuczenia. Model zamiast uogólniać wielowymiarowe reguły, próbuje zapamiętać zbiór, przez co staje się silnie podatny na losowość inicjalizacji wag i łatwo utyka w minimach lokalnych.